DATA · MACHINE LEARNING · DEEP LEARNING · SERVING

Olist 이커머스 데이터로 상품 · 리뷰 · 판매자 문제를 푸는 AI 프로젝트

브라질 마켓플레이스 Olist 공개 데이터(2016~2018)를 Google Colab에서 분석·학습하고,
저장한 모델 4개를 불러와 예측하는 **Streamlit 대시보드**로 서빙했습니다.

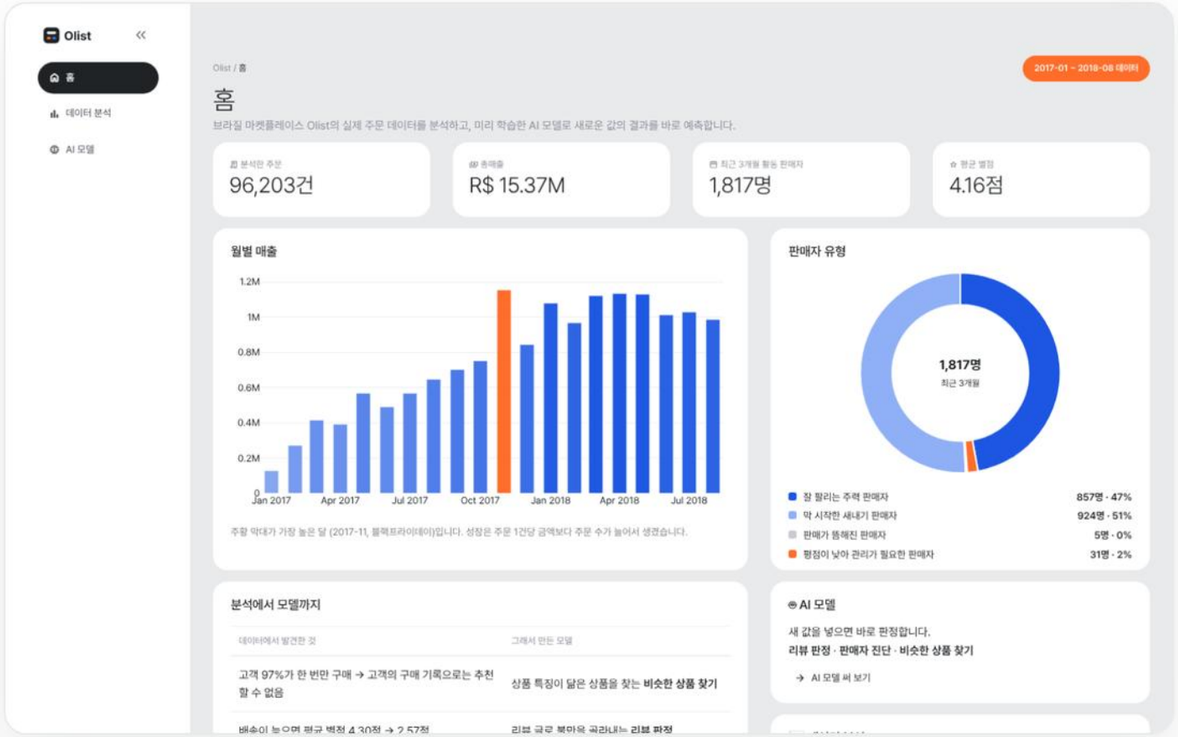
119,143
CSV 9개 병합 행 수 (40열)

10
EDA로 확인한 비즈니스 인사이트

4종
배포 모델 (합계 약 340KB)

96,203
대시보드 분석 주문 (배송 완료)

01 프로젝트 개요 · 문제 정의	**04~05** EDA 인사이트 10	**08** 판매자 유형 (K-Means)
03 데이터 준비 · 병합	**06** 유사 상품 추천	**09** 판매자 이탈 예측
10 서빙 대시보드 (STEP2)	**07** 리뷰 감성 분석	**11** 전략 제안 · 한계



사용 기술

Python · pandas · NumPy · Matplotlib
scikit-learn (KNN · LogisticRegression · RandomForest · K-Means · PCA)
TensorFlow/Keras (Embedding · Bi-LSTM) · Hugging Face BERT · Streamlit · Plotly · joblib · Google Colab

산출물

🔬 **STEP1 분석 · 학습**
PART 1~11 (Google Colab)

🧠 **models/ .pkl 4개**
추천 159KB · 감성 176KB · 유형 3KB · 이탈 2KB

📊 **Streamlit 대시보드**
홈 · 데이터 분석 · AI 모델 3페이지

🎬 **docs/**
데모 영상 · 발표 슬라이드 11장

데이터: Olist Brazilian E-Commerce Public Dataset (Kaggle, CC BY-NC-SA 4.0)

프로젝트 흐름과 문제 정의

데이터가 문제를 정했다

STEP1 분석·학습 → STEP2 서빙

전체 파이프라인

PART 1~4 데이터 준비
CSV 9개 이해 · 병합
119,143행 × 40열

→

PART 5 EDA
집계 단위 맞추기
인사이트 10가지 → 문제 정의

→

PART 6~9 모델
추천 · 감성 · 군집 · 이탈
단순 기준선과 먼저 비교

→

PART 10~11 전략 · 내보내기
최신 시점 적용 · 실행 목록
.pkl 4개 + 버전 기록

→

STEP2 대시보드
모델 불러와 예측만
Streamlit 3페이지

⚠️ 고객 기반 모델은 할 수 없었다

97.0%
한 번만 구매한 고객
(재구매 약 3%)

0.003%
고객 × 상품 표에서
채워진 칸 비율

협업 필터링("비슷한 고객이 산 상품")과 고객 이탈 예측("전부 이탈"만 찍어도 정확도 97%)은 배울 거리가 없습니다.

→ 그래서 문제를 다시 정의

- 고객 대신 **상품** : 상품 특징으로 "이 상품과 비슷한 상품"
- 고객 대신 **판매자** : 매달 반복 판매 → "판매 중단" 정의가 자연스러움
- 배송 지연 → 리뷰 급락 : **리뷰 글**로 불만 자동 분류

🔒 모든 모델에 적용한 검증 원칙

- **test 먼저 분리** → 끝까지 손대지 않는 시험지
- 단어집 · 스케일러 등 전처리는 **train으로만** 학습
- 판매자 모델은 **기준일 이전** 정보만 특징으로 (미래 누수 방지)
- 데이터가 작으면 **5-fold 교차검증**으로 평균과 흔들림 확인
- 불균형 문제는 정확도 대신 **재현율 · F1**

4가지 문제 · 방법 · 결과

문제	방법 (비교 대상)	핵심 결과	비즈니스 활용
유사 상품 추천 PART 6	카테고리 필터 + KNN vs 랜덤 · 가격 ±20% 규칙	기준 상품과의 특징 차이 **72% → 45% → 30%**	상품 페이지 "비슷한 상품"
리뷰 감성 분석 PART 7-1~7-3	TF-IDF + 로지스틱 회귀 vs Embedding · Bi-LSTM · BERT	정확도 **0.917** (기준선 0.710), 부정 F1 0.869 → 가볍고 정확한 ML 모델 배포	부정 리뷰 자동 분류 → CS 우선 대응
판매자 유형 PART 8	로그 변환 + K-Means 엘보우 · 실루엣으로 k=4	핵심 우량 876 · 신규 성장 947 · 휴면 461 · **저평점 위험 218명**	유형별 관리 정책
판매자 이탈 예측 PART 9	로지스틱 회귀 (balanced) vs 규칙 · 랜덤 포레스트	5-fold F1 **0.58** (규칙 0.53), 5번 모두 규칙보다 높음 · test 재현율 0.75	이탈 확률 × 판매액 우선순위

2,498개
추천 대상 상품

37,139건
감성 학습 리뷰

2,502명
유형 분석 판매자

1,567명
이탈 학습 판매자

📌 공통 원칙 : **단순한 방법과 먼저 비교하고, 나아질 때 복잡한 방법을 쓴다.** (PART 10 정리)

CSV 9개를 하나로 — 병합과 집계 단위 PART 2~4

olist_master_data.csv · 62.7MB

병합 순서와 행 수 변화 — 1:N 관계에서 행이 늘어남 (오류가 아니라 정상)

orders + customers	99,441
+ order_items **+13,984**	113,425
+ products · category	113,425
+ payments **+5,009**	118,434
+ reviews **+709**	119,143
+ sellers (최종 40열)	119,143

상품 2개 × 결제 2건이면 같은 주문이 **4행**이 됩니다. 리뷰가 2개 이상인 주문도 **547건** 있습니다.

99,441
고유 주문

96,096
고유 고객
(customer_unique_id)

32,951
고유 상품

40
통합 컬럼 수

그대로 더하면 틀린다 — 무엇을 세는지에 맞는 단위

세는 것	집계 기준	주의
주문 수 · 리뷰	`orders` (주문 1건 = 1행)	통합 표는 상품·결제·리뷰 행이 곱해져 있음
상품 · 카테고리	`items` (상품 1개 = 1행)	결제 행 중복 제거
매출	`pay` (주문별 결제 합)	1:N 결제를 주문별로 먼저 합침
재구매	`customer_unique_id`	`customer_id`는 주문마다 새로 발급

분석 기간 : 앞뒤 빈 구간을 뺀 **2017-01-05 ~ 2018-08-29, 배송 완료 주문**

테이블 연결 구조 (ID 기준)

customers
customer_id

↔

orders (중심)
order_id

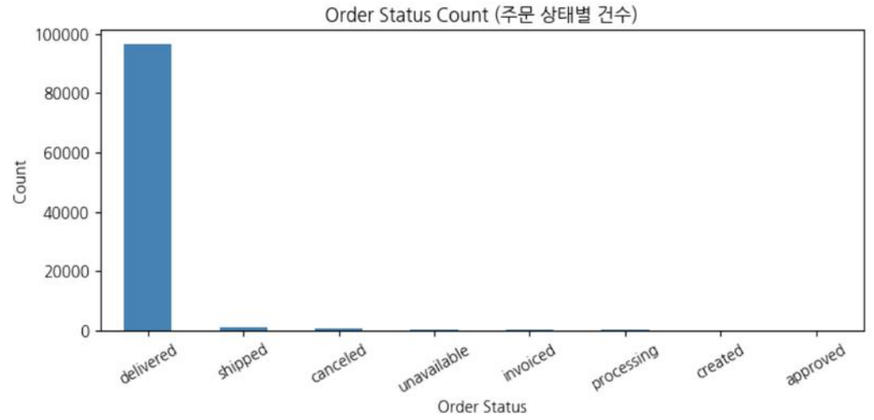
↔

items · payments · reviews
order_id (1:N)

↔

products · sellers
product_id · seller_id

주문 상태별 건수



대부분이 **delivered** → 분석은 배송 완료 주문 기준

리뷰 점수 분포



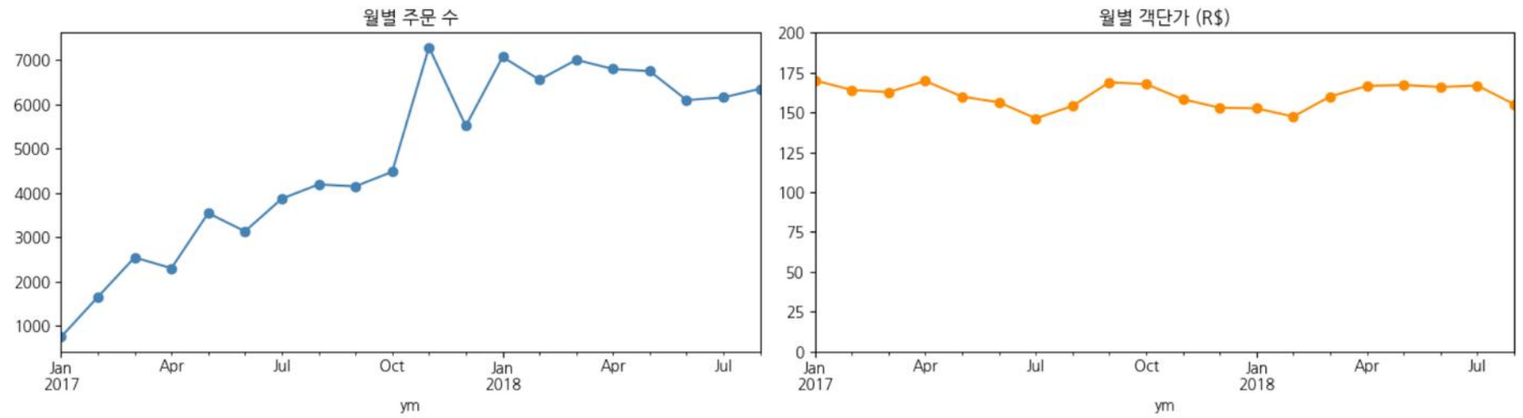
5점이 가장 많고 1점이 두 번째 → 감성 분석은 4·5점 긍정 / 1·2점 부정, 3점 제외

누가, 얼마나, 언제 사는가

인사이트 1~5 · PART 5

분석 기간 2017-01-05 ~ 2018-08-29

5 성장은 객단가가 아니라 주문 수 에서 왔다



월별 주문 수는 **2.40배**로 늘었지만 객단가는 **+1.4%**에 그침 → 다음 성장 레버는 객단가 (묶음 판매 · 추천)

1 고객 대부분이 한 번 사고 떠난다

97.0%
1회 구매 고객

1.07개
고객 1명이 산 상품 종류

- 고객 기반 추천 · 고객 이탈 예측의 근거가 사라짐
- → **상품** 기반 추천 (PART 6), **판매자** 이탈 (PART 9)
- 제안 : 첫 구매 후 재구매 쿠폰 · 알림

3 신용카드 할부가 구매의 기본

75.5%
신용카드 결제

66.8%
그중 할부

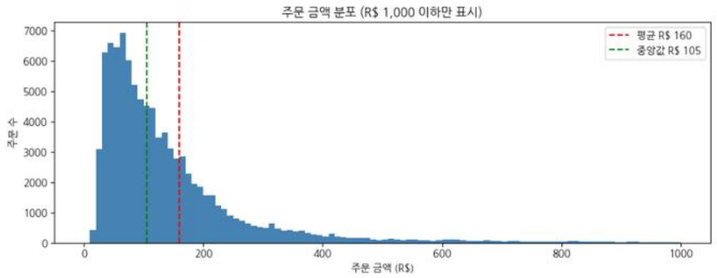
→ 무이자 할부 프로모션 (KPI 고가 상품 전환율)

2 고객은 남동부 3개 주에 몰려 있다



SP · RJ · MG 주문 **66.6%** → 지역별 마케팅 · 물류 배분

4 '보통 주문'은 평균보다 훨씬 작다



평균 **R$160** vs 중앙값 **R$105** → 프로모션 기준 금액은 분포로 설정

월별 매출 — 급락을 의심하기



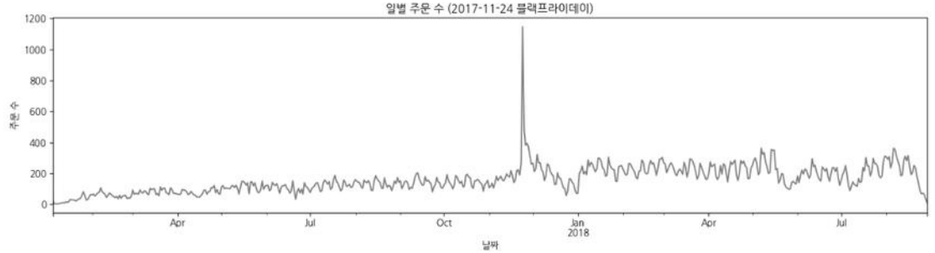
마지막 달 급락은 실제 하락이 아니라 **데이터 수집 종료** → 기간을 잘라 분석

그래프 : STEP1 Colab 분석 결과 (PART 5)

무엇이 팔리고, 배송은 리뷰를 어떻게 바꾸나 인사이트 6~10

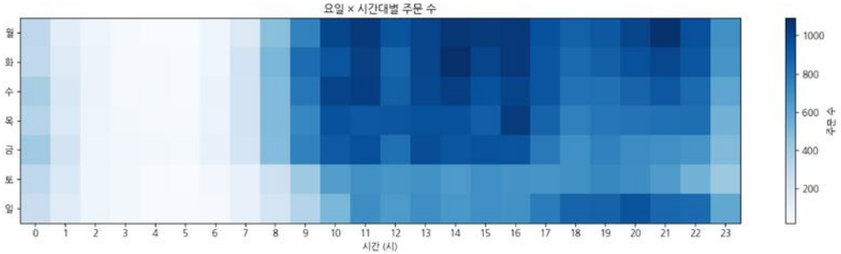
→ PART 7 · 8 문제 정의

6 블랙프라이데이 — 공정한 비교의 중요성



2017-11-24 하루 **1,147건** (평소 **7.8배**) → 같은 기간 · 이벤트를 고려해 비교, 성수기 재고 · 물류 사전 증원

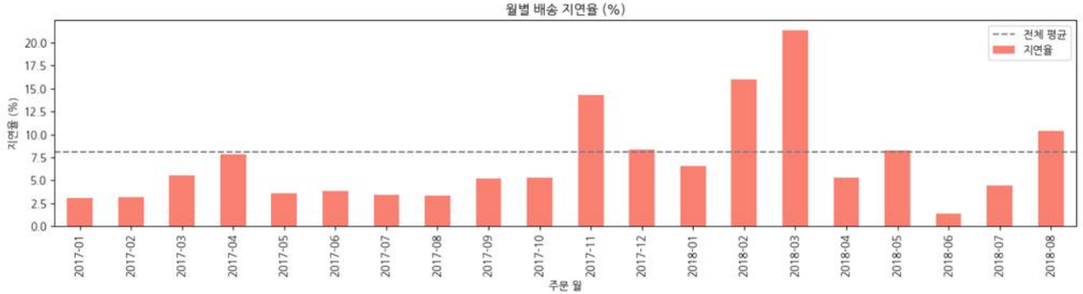
7 평일 낮에 사고, 새벽 · 주말에는 덜 산다

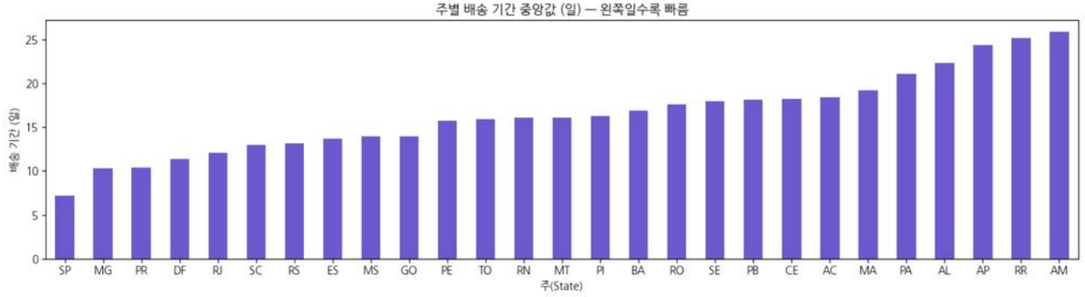


10~16시 **45.2%**, 0~5시 **4.8%** (단, 일요일 저녁은 높음) → 알림 · 타임 세일 · 상담 인력 시간대

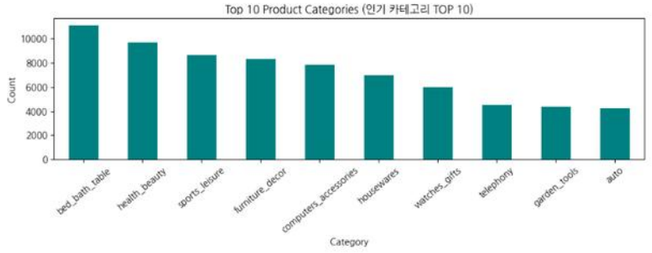
10 성수기와 먼 지역에서 배송이 늦어진다

월별 지연율 최고 **21.4%** (2018-03, 평균 8.1%) · 배송 기간 중앙값 SP **7.2일** vs 북부 **24~26일** → 예정일 현실화 · 지역 거점





8 많이 팔리는 것 ≠ 돈이 되는 것



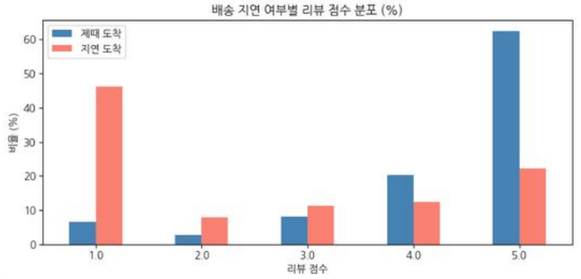
판매 개수 TOP 10 카테고리

watches_gifts 개수 7위 → 매출 **2위**

상위 17개 카테고리가 매출 **80%**

→ 핵심 카테고리 집중 관리

9 배송이 늦으면 리뷰가 무너진다



4.30→2.57
지연 시 평균 리뷰

7배
1점 리뷰 비율

→ 리뷰 글로 불만 분류 (PART 7), 지연이 몰린 판매자 찾기 (PART 8)

그래프 : STEP1 Colab 분석 결과 (PART 5)

같은 카테고리면 비슷한 상품일까? 유사 상품 추천 · PART 6

part6_recommend.pkl · 159KB

데이터 · 특징

- 원본 CSV → **상품 1개 = 1행** 특징표 직접 생성
- 거래 3건 이상 · 상위 15개 카테고리 → **2,498개**
- 특징 : 가격 · 무게 · 가로/세로/높이 · 사진 수 · 평점
- 치우친 값은 **로그 변환**, 단위 차이는 **스케일링**

핵심 아이디어

카테고리는 '종류'를 맞추는 **필터**,
숫자 특징은 '급'을 맞추는 **거리(KNN)**.

같은 카테고리 안에서도 가격은 몇 배, 무게는 열 배 넘게 차이

비교한 세 방법

① 같은 카테고리 랜덤
가장 단순한 기준선

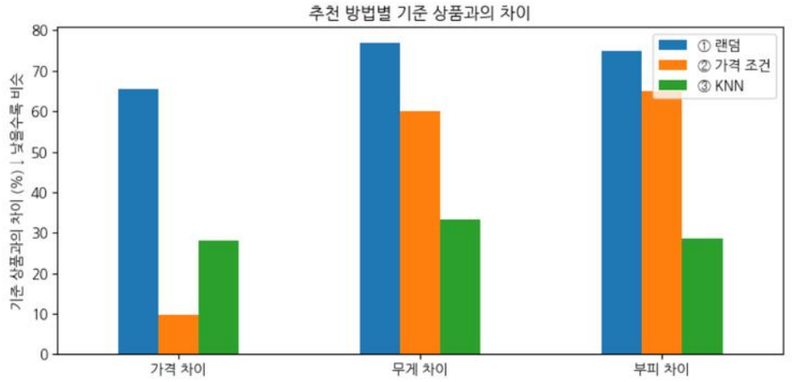
② + 가격 ±20% 조건
후보 5개를 못 채우는 상품
6%

③ 카테고리별 KNN (k=5)
같은 카테고리 안에서 가장 가까운 5개

저장 · 서빙

- 스케일러 + KNN + 상품 목록을 **한 파일**로 저장
- 대시보드 : **새 상품** 특징으로도 검색

추천 방법별 기준 상품과의 차이 (낮을수록 비슷)



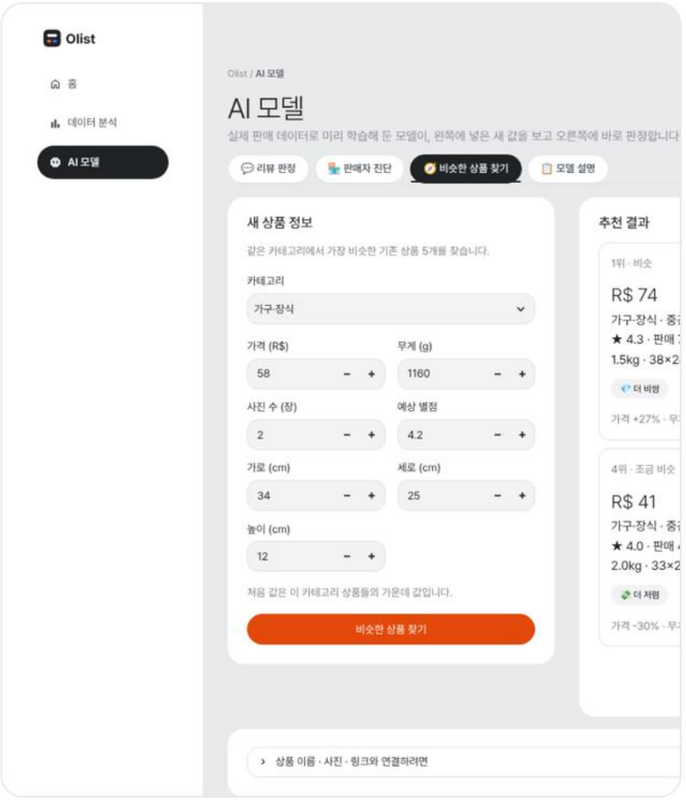
72% ① 랜덤

45% ② 가격 조건

30% ③ KNN

가격 · 무게 · 부피 차이의 평균. **가격만 보면 가격 조건이 1등** → 평가 기준을 여러 개로 잡아야 공정합니다.

대시보드 적용 — 새 상품 정보로 찾기



카테고리 · 가격 · 무게 · 크기를 넣으면 가장 비슷한 기존 상품 5개를 카드 + 산점도로 표시

한계

- 특징 유사도만 쟀을 뿐 **고객 반응은 모름** → A/B 테스트 필요
- 목록에 없는 상품은 추천 불가 (콜드 스타트)

그래프 : STEP1 Colab 분석 결과 (PART 6)

05 · SENTIMENT ANALYSIS

별점 없이 글만 보고 불만을 알 수 있을까? PART 7-1 · 7-2 · 7-3

part7_1_sentiment_ml.pkl · 176KB

데이터 · 라벨

37,139 리뷰 (중복 제거)

26,380 긍정 4·5점

10,759 부정 1·2점

글 없는 리뷰 · 3점 제외. test는 처음에 떼어 두고 끝까지 손대지 않음

누수 방지 · 불균형

- 단어집(TF-IDF · Tokenizer)은 **train으로만** 만들고 test는 변환만
- 딥러닝은 train에서 validation을 따로 떼어 EarlyStopping
- `class_weight`로 부정 클래스 보정
- 정확도만이 아니라 **부정 리뷰의 재현율 · F1**로 평가

로지스틱 회귀 가중치 상위 단어

긍정 단어	가중치	부정 단어	가중치
antes (기한 전에)	6.54	não (아니다)	−10.00
parabéns (칭찬)	4.94	péssima (최악)	−4.67
ótimo (훌륭한)	4.86	ruim (나쁜)	−3.93
rápida (빠른)	4.78	diferente (다른)	−3.85
excelente (탁월한)	4.70	aguardando (기다리는 중)	−3.48

별점만 보고 학습했는데도 부정 단어에서 **배송 지연 · 오배송 · 품질 · 파손** 유형이 드러남

같은 test로 비교한 정확도



부정 F1 : TF-IDF + 로지스틱 **0.869** · 딥러닝도 머신러닝과 **거의 같음** (리뷰가 짧고 핵심 단어로 판단되는 문제)

사전학습 BERT (학습 없이 사용, test 500건)



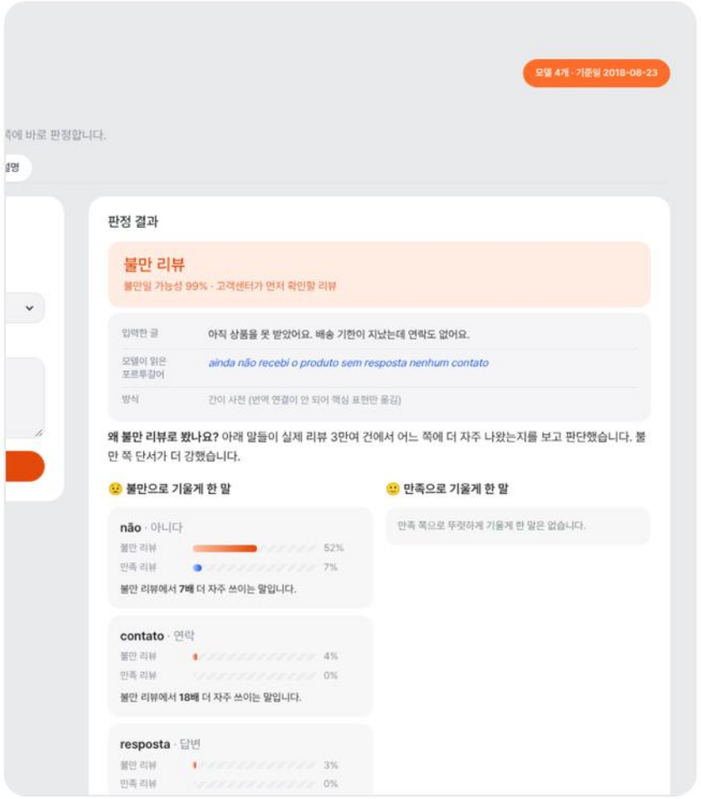
후보	정확도	파일 크기	판단
TF-IDF + 로지스틱	**0.917**	**176KB**	✅ **배포**
Embedding (Keras)	0.924	약 2.5MB	비교용
BERT (pipeline)	0.730	약 540MB	파인튜닝은 심화 과제

옵티마이저를 빼고 저장해 Keras 파일 7.5MB → 2.5MB

부정 단어를 묶어 보면

불만 유형	단어
배송 지연	aguardando · demora · passou (기다리는 중 · 오래 걸림 · 기한 지남)
오배송	diferente · comprei · errado (다른 · 샀는데 · 잘못된)
품질	péssimo · ruim · baixa · inferior (최악 · 나쁜 · 낮은 · 기대 이하)
파손	quebrado (깨진)

대시보드 적용 — 리뷰 판정



한국어 입력은 포르투갈어로 옮겨 판정하고, 판정 근거 단어가 실제 불만 · 만족 리뷰에 나온 비율을 함께 표시

한계

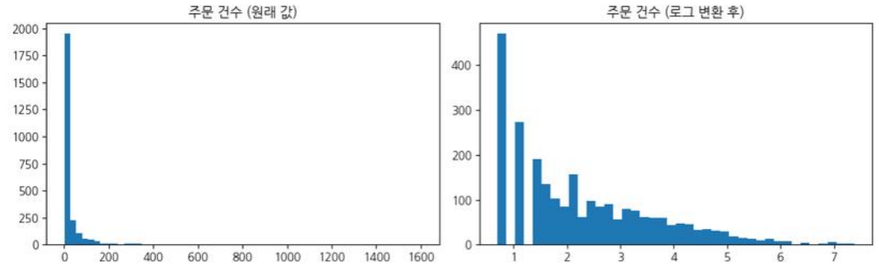
- 단어 순서를 보지 않아 부정어 · 문맥을 놓칠 수 있음
- 포르투갈어 리뷰로만 학습

수치 : STEP1 Colab 분석 결과 (PART 7-1 · 7-2 · 7-3)

Olist에는 어떤 판매자들이 있을까? 비지도 학습 K-Means · PART 8

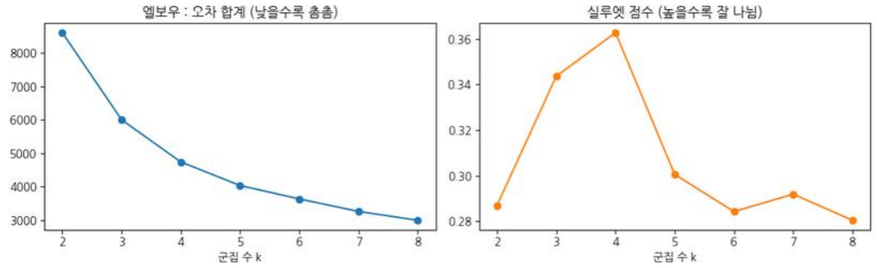
part8_seller_segment.pkl · 3KB

1 로그 변환 전후 — 주문 건수 분포



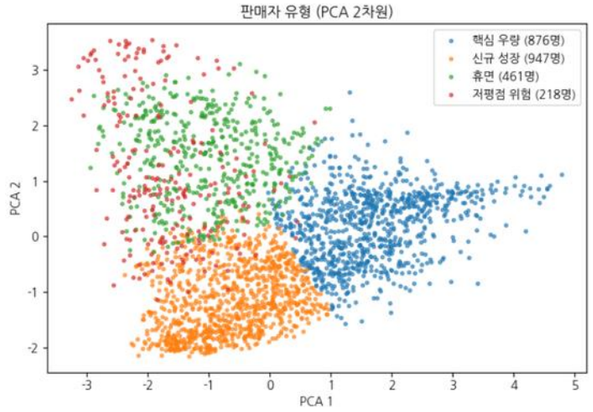
로그 변환을 안 하면 대형 판매자 **22명**이 군집 하나를 통째로 차지 (군집 크기 1,255 · 670 · 555 · 22)

2 k 정하기 — 엘보우로 후보, 실루엣으로 결정



실루엣 점수가 가장 높은 **k = 4**

3 판매자 유형 (PCA 2차원)



- 원본 CSV에서 기준일 **2018-05-31**까지의 유효 주문으로 판매자 **2,502명** 프로필 생성
- 특징 : 주문 수 · 판매액(로그) · 마지막 판매 후 일수 · 판매 기간 · 평균 별점
- 정답이 없는 문제 → 군집 결과에 **사람이 해석해서 이름**을 붙임
- 스케일러 + K-Means + 유형 이름 + 결측 채움 값을 한 파일로 저장

4 4가지 유형과 관리 방향

유형	판매자	특징	관리 방향
핵심 우량	876	주문이 많고 최근에도 꾸준히 판매	우수 판매자 혜택
신규 성장	947	시작한 지 얼마 안 됨	온보딩 · 첫 리뷰 관리
휴면	461	오랫동안 판매 없음	재활성 제안
저평점 위험	**218**	**평균 배송 약 22일, 출고 지연율 약 33%**	**출고 마감 준수 관리**

💡 저평점 위험 유형은 택배 운송이 아니라 **판매자 출고 단계부터** 늦음 → 인사이트 9 · 10과 연결

최신 시점(2018-08-23) 활동 판매자 1,817명 · 유형 × 이탈 위험 PART 10

유형	낮음	보통	높음	매우 높음
핵심 우량	498	149	106	104
신규 성장	244	288	219	173
휴면 · 저평점 위험	0	1	7	28

그래프 : STEP1 Colab 분석 결과 (PART 8)

앞으로 3개월 동안 판매를 멈출 판매자는? 분류 · PART 9

part9_seller_churn.pkl · 2KB

이탈을 데이터로 정의

2018-03~05 활동 판매자가 이후 3개월 동안 **유효 주문 0건** → 이탈

실제 폐업이 아닌 **실습용 정의**

시간으로 나눠 누수 방지

과거 → 특징
기준일 2018-06-01 이전 기록만

미래 → 정답
기준일 이후 3개월 주문 여부

test 먼저 분리
train만으로 규칙 · 모델 비교

1,567
대상 판매자

24.1%
이탈 비율 (불균형)

유형별 이탈률 (PART 8 연결)

핵심 우량 **17%** ~ 저평점 위험 **66%**

유형은 해석에 유용하지만, 특징으로 넣어도 성능은 오르지 않음 (새 정보가 없음)

5-fold 교차검증 (train) — 규칙과 먼저 비교

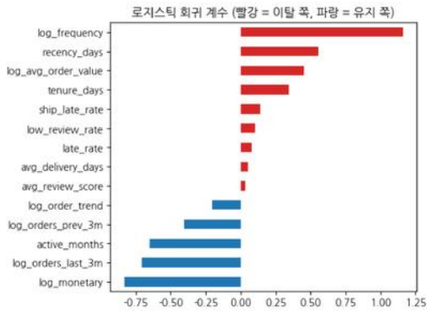
모델	정밀도	재현율	F1	AUC	F1 ±
규칙 (최근 30일 판매 없음)	0.49	0.58	0.53	0.77	0.04
로지스틱 회귀	0.59	0.32	0.40	0.79	0.05
로지스틱 회귀 + balanced	**0.47**	**0.75**	**0.58**	**0.80**	**0.04**
랜덤 포레스트	0.59	0.29	0.38	0.80	0.04
랜덤 포레스트 + balanced	0.48	0.67	0.55	0.80	0.07

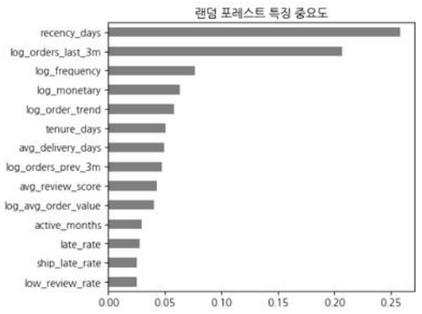
0.3 → 0.75
class_weight로 재현율 상승

5 / 5
fold마다 규칙보다 F1 높음 (로지스틱)

2 / 5
랜덤 포레스트

판단 근거 — 계수 · 중요도





test 최종 평가 (314명, 1회)

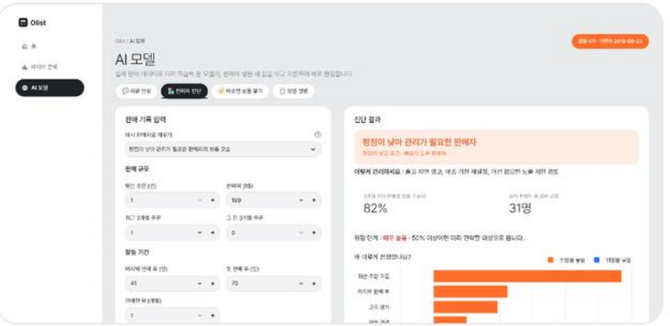
모델	정밀도	재현율	F1
규칙 (30일)	0.47	0.60	0.53
로지스틱 + balanced	**0.43**	**0.75**	**0.55**
랜덤 포레스트 + balanced	0.44	0.71	0.55

test가 작아 몇 명 차이로 순위가 바뀜 → **교차검증에서 꾸준한 로지스틱 회귀**를 배포

혼동 행렬	예측 유지	예측 이탈
실제 유지 (238)	164	74
실제 이탈 (76)	**19**	**57**

이탈 76명 중 57명을 미리 찾는 대신 헛경보 74명 → **놓치지 않는 쪽**을 선택

대시보드 적용 — 판매자 진단



판매 기록 입력 → 유형 · 3개월 내 판매 중단 가능성 · 위험 요인

수치 · 그래프 : STEP1 Colab 분석 결과 (PART 9)

분석에서 서비스로 — Streamlit 대시보드

학습 없이 저장한 모델로 예측만

`streamlit run app.py`

서빙 구조

PART 11 모델 내보내기
Colab에서 .pkl 4개 + 버전 기록을 zip으로

export_serving_data.py
원본 CSV → `data/` 작은 파일 5개 (학습과 같은 판매자 특징 함수)

serving.py
모델 4개 불러오기 + 예측 함수 (Streamlit 의존 없음)

app.py · views/ · ui.py
3페이지 화면 · 공통 디자인 · 캐시

약 340KB
모델 4개 합계 → 작은 서버에서도 서빙

2018-08-23
최신 기준일로 판매자 특징 재계산

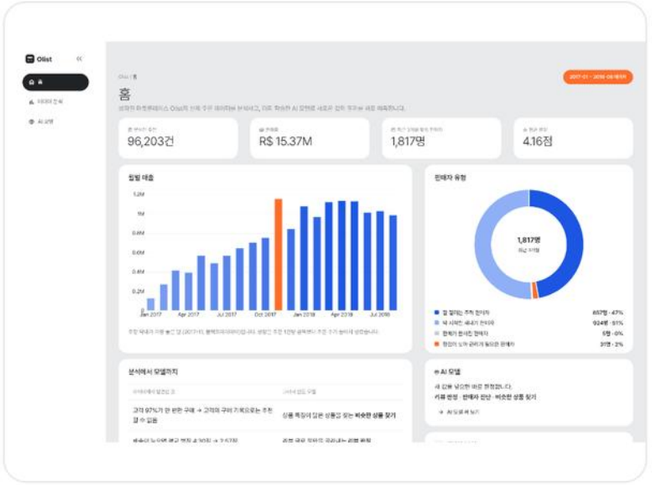
주의한 점

- .pkl은 만든 환경과 **같은 scikit-learn 버전**에서만 안전 → requirements.txt 버전 고정
- 모델 · 데이터는 `st.cache_resource` · `st.cache_data`로 한 번만 로드
- 모델 파일이 없으면 안내 메시지 후 실행 중단

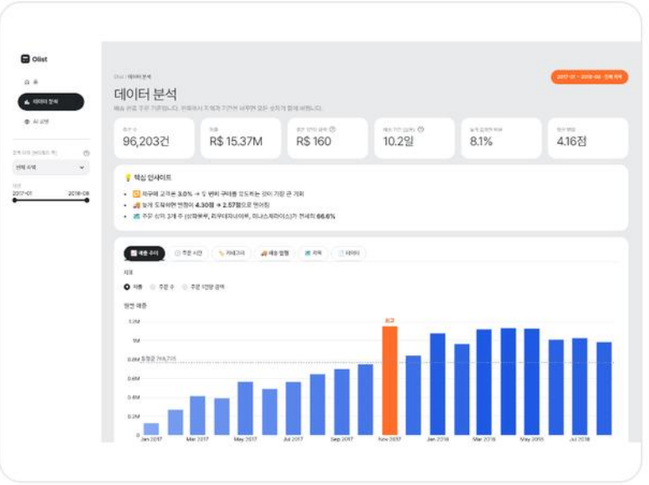
data/ 서빙용 파일 (.csv.gz)

orders	배송 완료 주문 96,203건 (긴 ID → 짧은 번호)
items · products_info	카테고리 · 판매 실적
sellers_latest	기준일 판매자 특징 (PART 8 · 9 입력)
reviews_recent · word_stats	최근 리뷰 · 판정 근거 단어 통계

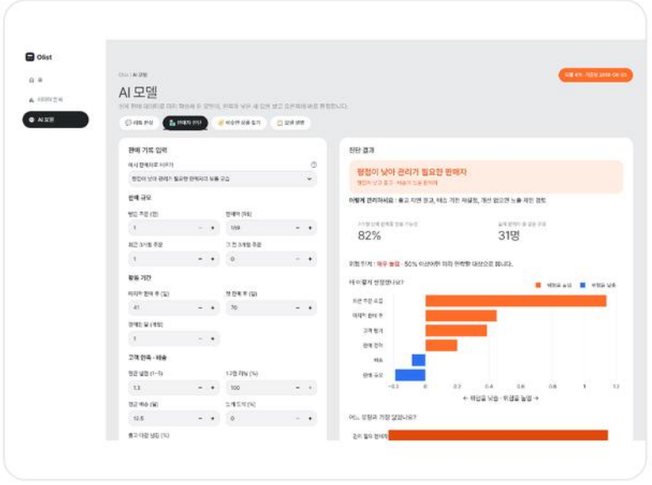
🏠 홈 — 핵심 숫자 · 판매자 유형



📊 데이터 분석 — 필터 · 탭 6개



🏪 AI 모델 — 판매자 진단



대시보드 기능

페이지	보여 주는 것
홈	주문 · 매출 · 활동 판매자 · 평균 별점, 월별 매출, 유형 비율
데이터 분석	지역 · 기간 필터, 핵심 지표 6개, 인사이트, 매출 · 시간 · 카테고리 · 배송 · 지역 · 원본 표
AI 모델	리뷰 판정 · 판매자 진단 · 비슷한 상품 찾기 · 모델 설명

데모 영상 : docs/demo/olist_dashboard_demo.mp4

화면 : 로컬 실행 대시보드 캡처

문제 → 근거 → 실행 → 측정

PART 10 비즈니스 전략

우선순위 = 확률 × 영향

전략 제안

문제 (PART 5)	근거 (모델)	실행	측정 지표 (KPI)
재구매 3%, 성장이 신규 유입에만 의존 (인사이트 1 · 5)	PART 6 유사 상품 추천	상품 페이지 · 장바구니에 "비슷한 상품" 노출 → 객단가 · 추가 구매 유도	추천 클릭률, 주문당 상품 수, 객단가
배송 지연 → 리뷰 급락 (인사이트 9)	PART 7-1 감성 분류	부정 리뷰 자동 분류 → CS팀 우선 대응, 별점 높은 불만 리뷰도 포착	부정 리뷰 응답 시간, 재리뷰 평점
지연 · 저평점이 일부 판매자에게 몰림 (인사이트 9 · 10)	PART 8 판매자 유형	저평점 위험 → 출고 마감 준수 관리 / 신규 성장 → 온보딩 / 핵심 우량 → 우수 판매자 혜택	유형별 출고 지연율, 평균 평점
판매자가 떠나면 상품 구색과 매출이 줄어듦	PART 9 이탈 확률	이탈 확률 × 판매액으로 우선순위 → 담당자 연락, 광고 · 수수료 지원	3개월 뒤 실제 이탈률, 유지된 판매액

최신 시점(2018-08-23)에 모델 적용

637명
활동 판매자 1,817명 중 이탈 확률 0.5 이상

23건
별점 4~5점인데 강한 부정 (확률 0.9 이상)

3,471건
2018-08 이후 글 있는 리뷰

23.3% → 33.1%
별점 1~2점 비율 → 모델이 부정으로 본 비율

예) "AINDA NÃO RECEBI O PRODUTO" (아직 상품을 못 받았다) — 별점 4점

모델 학습 시점(2018-06-01)이 아니라 **데이터의 마지막 시점**에 적용해 연락할 판매자 · 확인할 리뷰 목록을 만듦

왜 고객 기반 모델을 하지 않았나

- 1회 구매 고객 **97.0%**
- 고객 × 상품 표 채워진 칸 **0.003%** → 협업 필터링 불가
- 고객 이탈은 "전부 이탈"만 찍어도 정확도 97% → 의미 없는 문제

→ 상품(추천) · 판매자(유형 · 이탈)로 문제를 다시 정의

STEP2 전 모델 파일 점검

파일	구분	크기
part6_recommend.pkl	배포	159KB
part7_1_sentiment_ml.pkl	배포	176KB
part7_2_sentiment_model.keras	비교용	2,541KB
part8_seller_segment.pkl	배포	3KB
part9_seller_churn.pkl	배포	2KB

배포용 4개 합계 **340KB** → 작은 서버에서도 서빙 가능

한계와 다음 단계

한계	다음 단계
추천은 고객 반응을 모름	A/B 테스트로 클릭률 · 전환율 확인
이탈 정의는 실습용	실제 탈퇴 · 휴면 정책과 맞춰 재정의
2018-06 시점 학습	3개월마다 재학습 · 성능 비교
감성 모델은 포르투갈어로만 학습	새 언어 · 표현 데이터 추가 후 재학습

📌 **단순한 방법과 먼저 비교하고, 나아질 때 복잡한 방법을 쓴다.**

추천 : 랜덤 · 가격 규칙 → KNN / 감성 : 전부 긍정 → ML → 딥러닝 · BERT / 이탈 : 30일 규칙 → 로지스틱 · 랜덤 포레스트